

# Compte-rendu de TP

## RAG - Assistant Médical

### *Sujet B : Assistant Médicaments*

Base de données utilisée : Base de Données Publique des Médicaments (BDPM) - [data.gouv.fr](https://data.gouv.fr)

Durée estimée : environ 6 heures

### Objectif du projet

Concevoir un assistant médical basé sur une architecture RAG capable d'orienter l'utilisateur vers des informations fiables sur les médicaments à partir de la BDPM. Le système repose sur deux agents collaboratifs : le premier structure le profil patient, tandis que le second interroge la base documentaire et applique une analyse médicale ordonnée selon le contexte fourni.

### 1. Architecture retenue

Le système est organisé autour de deux agents collaboratifs connectés à une base vectorielle FAISS :

- Agent 1 : collecte les informations utiles sur le patient (symptômes, âge, poids, grossesse, traitements en cours, allergies) dans une conversation naturelle, puis les transforme en JSON structuré.
- Agent 2 : reçoit ce profil, interroge la base FAISS, réévalue les résultats selon le contexte patient, puis produit une analyse dans un ordre strict : conditions de prescription, contre-indications, interactions, grossesse, posologie et effets indésirables.

### 2. Décisions de conception

1. **Chunking par priorité de section** : Les notices médicales ne présentent pas toutes le même niveau de criticité. Les sections sensibles (contre-indications, interactions, grossesse/allaitement) ont été découpées en chunks d'environ 300 caractères afin de maximiser la précision de récupération. Les sections secondaires (indications, composition) utilisent des chunks plus larges, autour de 700 caractères. Cette approche permet de faire remonter en priorité les informations les plus utiles pour la sécurité du patient.
2. **Re-scoring FAISS** : Les résultats récupérés par FAISS sont reclassés dynamiquement selon le profil du patient. Par exemple, si le patient est enceinte, les chunks liés à la grossesse et à l'allaitement sont valorisés ; s'il prend déjà des médicaments, les chunks liés aux interactions bénéficient d'un bonus. Ce mécanisme améliore la pertinence sans modifier l'index lui-même.
3. **Modèle d'embedding multilingue** : Le modèle paraphrase-multilingual-MiniLM-L12-v2 a été retenu pour sa compatibilité avec le français, langue principale des notices BDPM, tout en restant léger et rapide à l'exécution.
4. **Connexion unique au LLM** : Le pattern Singleton mis en place dans `llm_client.py` garantit une initialisation unique de la connexion à l'API Groq, ce qui évite les reconnexion inutiles à chaque appel.

5. **Idempotence de l'indexation** : Le script `load_or_create_index.py` vérifie l'existence et la cohérence de la base avant de lancer une nouvelle construction. Cette logique évite de relancer une indexation coûteuse à chaque démarrage.

### 3. Difficultés rencontrées

- **Volume des données** : Avec 15 649 médicaments et près de 950 000 chunks, l'indexation complète a nécessité un traitement par lots de 500 médicaments avec sauvegarde intermédiaire après chaque batch. Cette organisation a permis de sécuriser le travail et d'éviter toute perte importante en cas d'interruption.
- **Téléchargement du modèle** : Le modèle initial, `paraphrase-multilingual-mpnet-base-v2`, posait des difficultés de téléchargement en raison de limitations de débit sur Hugging Face sans authentification. Le remplacement par `paraphrase-multilingual-MiniLM-L12-v2`, plus léger (471 Mo), a résolu ce problème.
- **Encodage des données** : Le fichier source BDPM est encodé en latin-1 et contient du HTML imbriqué dans un TSV. L'association de pandas, BeautifulSoup et lxml a permis d'extraire correctement les 16 sections de chaque notice.

### 4. Résultats obtenus

| Indicateur          | Valeur                                             |
|---------------------|----------------------------------------------------|
| Médicaments indexés | 12 009                                             |
| Chunks total        | 949 301                                            |
| Temps d'indexation  | environ 2 heures                                   |
| Modèle d'embedding  | <code>paraphrase-multilingual-MiniLM-L12-v2</code> |
| LLM                 | LLaMA 3.3 70B via Groq                             |
| Interface           | Streamlit                                          |

Ces résultats montrent qu'il est possible de construire une chaîne RAG robuste à partir d'une base documentaire médicale volumineuse, tout en conservant une logique de récupération orientée sécurité et pertinence.

### 5. Conclusion

Ce TP a permis de mettre en place un assistant médical structuré, capable de transformer un échange naturel en profil patient exploitable, puis de rechercher et hiérarchiser les informations utiles dans une base de médicaments. Les choix techniques retenus, en particulier le chunking par criticité, le re-scoring contextuel et l'indexation progressive, renforcent la fiabilité du système et constituent une base solide pour des améliorations futures.